

豆瓣电影 Top200 数据分析项目

结果展示在前，复现流程在后

1. 结果总览

本项目分析豆瓣电影 Top250 公开榜单前 200 部影片，重点呈现评分分布、类型结构、国家/地区来源、年代分布和排名关系。下表为本次数据快照的核心结果。

项目	说明
电影数量	200 部
年份跨度	1936-2023
平均评分	9.01
中位评分	9.00
评分范围	8.5-9.7
累计评价人数	188,548,326
出现最多的类型	剧情
出现最多的国家/地区	美国
数量最多的年代	2000 年代

2. 主要发现

- Top200 电影评分集中在 8.8-9.3 区间，整体评分水平很高。
- 剧情片出现 150 次，是榜单中最突出的类型标签。
- 美国电影出现 110 次，在国家/地区来源中占比最高。
- 1990 年代、2000 年代和 2010 年代影片构成榜单主体，其中 2000 年代数量最多。
- 排名越靠前评分整体越高；评分与评价人数之间的线性相关性较弱。

3. 类型与地区结构

类型分布显示，剧情片是 Top200 中最主要的标签，喜剧、爱情、冒险、奇幻和犯罪等类型也具有较高出现频次。国家/地区分布中，美国电影数量最多，日本、英国、中国香港、中国大陆和法国等也形成较明显的代表性。

类型	出现次数	国家/地区	出现次数
剧情	150 次	美国	110 次
喜剧	44 次	英国	28 次
爱情	43 次	日本	28 次
冒险	41 次	中国香港	24 次
奇幻	39 次	中国大陆	22 次
犯罪	36 次	法国	16 次
动画	34 次	韩国	11 次
惊悚	27 次	意大利	9 次

4. 可视化结果




图 1 Top200 电影评分分布




图 2 热门电影类型出现次数




图 3 主要制片国家/地区出现次数




图 4 不同年代电影数量




图 5 排名与评分关系

5. 项目输出

项目	说明
清洗数据	data/processed/movies_clean.csv
类型展开表	data/processed/movies_by_genre.csv
国家/地区展开表	data/processed/movies_by_country.csv
统计摘要	data/processed/analysis_summary.json
分析图表	output/figures/*.png
展示报告	GitHub 展示版 DOCX/PDF

6. 可复现操作

项目	说明
安装依赖	<code>python -m venv .venv; .venv\Scripts\python.exe -m pip install -r requirements.txt</code>
离线复现	<code>python run_pipeline.py --skip-fetch --student-name ... --student-id ... --class-name ...</code>
重新采集	<code>python run_pipeline.py --fetch --student-name ... --student-id ... --class-name ...</code>
重建展示报告	<code>python scripts/build_github_showcase_report.py</code>
运行测试	<code>python -m pytest -q</code>

7. 项目实现说明

项目	说明
采集层	分页访问公开榜单页面，解析排名、片名、年份、国家/地区、类型、评分和评价人数。
清洗层	统一字段类型，处理多值字段，移除重复项，并输出一电影一行的主表。
分析层	生成评分、类型、国家/地区、年代和相关关系统计。
输出层	保存 CSV/JSON、PNG 图表、Word 报告和 PDF 报告。

8. 局限性

- 榜单数据代表公开页面的一次快照，不能直接外推到全部电影市场。
- 类型与国家/地区为多值字段，当前按出现次数统计。
- 当前项目以探索性分析为主，后续可加入交互式看板、自动化 CI 和更丰富的文本分析。