

豆瓣电影 Top200 数据分析报告

基于公开榜单数据的描述统计、分组比较与可复现建模

1. 研究对象与结论摘要

本报告使用仓库内保存的豆瓣电影 Top250 公开榜单前 200 部影片作为样本，分析对象为影片排名、上映年份、国家/地区、类型、评分和评价人数等字段。数据口径为一部电影一条主记录；类型和国家/地区属于多值字段，在分布统计中按展开后的出现次数计算。

总体来看，样本评分均值为 9.01，中位数为 9.00，四分位区间为 8.8-9.2。这说明 Top200 榜单是一个明显的高分截断样本，分析重点不应放在“是否高分”，而应放在高分影片内部的结构差异。

项目	说明
电影数量	200 部
年份跨度	1936-2023
平均评分 / 中位评分	9.01 / 9.00
评分标准差	0.24
评分范围	8.5-9.7
累计评价人数	188,548,326
评价人数中位数	809,723
出现最多的类型	剧情
出现最多的国家/地区	美国
数量最多的年代	2000 年代（60 部）

2. 数据质量与统计口径

清洗过程保留了 200 条有效记录，排名字段唯一，年份、国家/地区和类型字段均无清洗后缺失。由于榜单电影常同时属于多个类型或多个制片地区，后续类型与地区统计采用展开表：同一部电影可能在多个标签下各计一次，因此这些次数用于描述结构，不等同于互斥分类占比。

项目	说明
原始记录数	200 条

清洗后记录数	200 条
无效记录剔除数	0 条
重复排名剔除数	0 条
重复片名年份剔除数	0 条
年份缺失	0 条
国家/地区缺失	0 条
类型缺失	0 条
排名唯一性	通过

3. 评分分布分析

评分分布集中在 8.8-9.3 分之间。样本最低分为 8.5，最高分为 9.7，标准差只有 0.24，说明榜单内部评分差异相对有限。若只看均值，容易忽略这种“高分样本内部再排序”的特点，因此下面按评分区间拆分观察。

评分区间	电影数量	占样本比例
8.5-8.7	27 部	13.5%
8.8-9.0	90 部	45.0%
9.1-9.3	65 部	32.5%
9.4-9.6	17 部	8.5%
9.7 及以上	1 部	0.5%

从区间分布看，8.8-9.0 分影片最多，9.1-9.3 分次之，9.4 分以上影片数量明显减少。这种分布说明 Top200 影片整体质量接近，但头部高分影片仍具有较强区分度。

4. 类型、地区与年代分析

- 剧情片出现 150 次，是样本中最突出的类型标签。
- 美国电影出现 110 次，是国家/地区来源中的最高频标签。
- 2000 年代影片数量最多，共 60 部；1990 年代和 2010 年代也占据较大比例。
- 类型和地区平均分只能解释样本内部差异，不能直接推出某一类型或地区整体质量更高。

类型	出现次数	国家/地区	出现次数
----	------	-------	------

剧情	150 次	美国	110 次
喜剧	44 次	英国	28 次
爱情	43 次	日本	28 次
冒险	41 次	中国香港	24 次
奇幻	39 次	中国大陆	22 次
犯罪	36 次	法国	16 次
动画	34 次	韩国	11 次
惊悚	27 次	意大利	9 次

按出现次数较多的类型继续比较平均评分，可以看到剧情、家庭、科幻等标签的平均分略高，但差距整体较小。由于电影类型是多标签字段，同一电影可能同时贡献给多个类型，本表更适合观察结构，而不是做因果判断。

类型	出现次数	平均评分
剧情	150 次	9.043
喜剧	44 次	8.959
爱情	43 次	8.984
冒险	41 次	8.988
奇幻	39 次	8.964
犯罪	36 次	8.967
动画	34 次	8.974
惊悚	27 次	8.907

国家/地区分布中，美国样本量最大，中国大陆、意大利、德国等标签的样本平均分较高，但其中部分地区样本数较小，解读时需要同时看数量和均值。

国家/地区	出现次数	平均评分
美国	110 次	9.007
英国	28 次	9.014
日本	28 次	8.968
中国香港	24 次	8.925

中国大陆	22 次	9.118
法国	16 次	9.044
韩国	11 次	8.945
意大利	9 次	9.144

年代分布显示，1990 年代、2000 年代和 2010 年代构成榜单主体。早期年代的平均分较高，但样本量明显偏少，因此更适合作为经典影片留存现象的提示，而不是年代优劣比较。

年代	电影数量	平均评分
1930 年代	2 部	9.300
1950 年代	5 部	9.300
1960 年代	4 部	9.100
1970 年代	4 部	9.225
1980 年代	15 部	9.127
1990 年代	49 部	9.065
2000 年代	60 部	8.982
2010 年代	58 部	8.907
2020 年代	3 部	9.033

5. 排名、评价人数与评分关系

排名与评分的 Spearman 秩相关系数为 -0.706 ， p 值为 <0.001 。由于排名数字越小表示位置越靠前，负相关说明评分越高的电影通常排名越靠前，这与榜单排序逻辑一致。

评分与评价人数对数之间的相关性较弱：Pearson 相关系数为 0.085 ， p 值为 0.234 ；Spearman 相关系数为 0.073 ， p 值为 0.307 。因此，在该样本中，评价人数多并不必然对应更高评分。

排名	影片	评分	评价人数
1	肖申克的救赎	9.7	3,298,535
8	这个杀手不太冷	9.4	2,560,665
5	千与千寻	9.4	2,548,105
3	泰坦尼克号	9.5	2,509,821
4	阿甘正传	9.5	2,439,595
2	霸王别姬	9.6	2,434,082
33	我不是药神	9.0	2,360,315
9	盗梦空间	9.4	2,334,656

6. 机器学习补充分析

机器学习部分只作为补充分析，用来检验现有结构化特征是否能解释一部分评分差异。特征包括年份、距今年数、评价人数对数、类型标签数、国家/地区数，以及热门类型和国家/地区的多热编码。模型采用 5 折交叉验证，并与平均分基线对照。

模型	MAE	RMSE	R^2
平均分基线	0.2034	0.2426	-0.0088
岭回归	0.1700	0.2172	0.1814
随机森林	0.1459	0.1837	0.4171

随机森林的 MAE 为 0.1459 ，比平均分基线低 0.0575 ，相对改善约 28.3% 。这说明特征中确实包含一定解释信息，但样本只有 200 条，且评分范围窄，模型结果应理解为探索性证据。

置换特征重要性显示，评价人数（对数）、上映年份、距今年数和类型标签数对误差影响较大。该结果与前面的描述统计相互补充：热度、年代和内容结构会影响榜单内部评分差异，但不能解释为因果关系。

特征	重要性均值	标准差
评价人数（对数）	0.0798	0.0049
上映年份	0.0290	0.0033
距今年数	0.0290	0.0033
类型标签数	0.0158	0.0027
类型：剧情	0.0076	0.0016
类型：爱情	0.0056	0.0013
地区：中国香港	0.0044	0.0010
国家/地区数	0.0035	0.0007

KMeans 分群将影片划分为若干内容画像，便于从结构上理解榜单组成。分群结果不是人工分类标准，而是根据年份、热度、类型和地区等特征形成的相似性分组。

分群画像	数量	平均评分	代表影片
华语剧情高口碑片	26	8.946	霸王别姬、背靠背，脸对脸、活着、鬼子来了
欧美剧情经典片	98	9.074	肖申克的救赎、泰坦尼克号、阿甘正传、美丽人生
悬疑惊悚与犯罪片	31	8.910	控方证人、盗梦空间、无间道、蝙蝠侠：黑暗骑士
动画奇幻与冒险片	45	8.978	千与千寻、星际穿越、大闹天宫、疯狂动物城

7. 可视化结果




图 1 Top200 电影评分分布




图 2 热门电影类型出现次数




图 3 主要制片国家/地区出现次数




图 4 不同年代电影数量




图 5 排名与评分关系




图 6 机器学习评分预测 MAE 对比




图 7 随机森林置换特征重要性




图 8 电影画像分群二维投影

8. 项目输出与可复现操作

仓库保留了原始数据、清洗数据、统计摘要、机器学习摘要、图表和报告生成脚本。复现时既可以使用仓库内保存的原始 CSV 离线生成结果，也可以重新访问公开榜单页面刷新数据。

项目	说明
清洗数据	data/processed/movies_clean.csv
类型展开表	data/processed/movies_by_genre.csv
国家/地区展开表	data/processed/movies_by_country.csv
统计摘要	data/processed/analysis_summary.json
机器学习摘要	data/processed/ml_summary.json
电影分群结果	data/processed/movie_ml_clusters.csv
分析图表	output/figures/*.png
展示报告	GitHub 展示版 DOCX/PDF
项目	说明
安装依赖	<code>python -m venv .venv; .venv\Scripts\python.exe -m pip install -r requirements.txt</code>
离线复现	<code>python run_pipeline.py --skip-fetch --student-name ... --student-id ... --class-name ...</code>
重新采集	<code>python run_pipeline.py --fetch --student-name ... --student-id ... --class-name ...</code>
运行 ML 扩展	<code>python scripts/run_ml_extension.py</code>
重建展示报告	<code>python scripts/build_github_showcase_report.py</code>
运行测试	<code>python -m pytest -q</code>

9. 项目实施说明

项目	说明
采集层	分页访问公开榜单页面，解析排名、片名、年份、国家/地区、类型、评分和评价人数。

清洗层	统一字段类型，处理多值字段，移除重复项，并输出一电影一行的主表。
分析层	生成评分、类型、国家/地区、年代和相关关系统计。
建模层	执行评分预测交叉验证、随机森林特征重要性分析和 KMeans 电影分群。
输出层	保存 CSV/JSON、PNG 图表、Word 报告和 PDF 报告。

10. 局限性与改进方向

- 样本来自豆瓣 Top250 前 200 名，是高口碑影片集合，不代表全部电影市场，也不能用于估计普通电影评分分布。
- 榜单页面会随时间变化，本报告反映当前仓库数据快照。若重新采集，评分、评价人数和排名可能发生变化。
- 类型与国家/地区为多值字段，展开统计会重复计入同一电影，因此不应把类型或地区次数相加后解释为互斥比例。
- 相关系数和机器学习结果只说明样本内特征关系，不能证明评分由某个类型、地区或年代直接导致。
- 后续可以补充评论文本情感分析、时间序列更新、交互式看板和 GitHub Actions 自动复现实验流程。