

豆瓣电影 Top200 数据分析项目

结果展示在前，复现流程在后

1. 结果总览

本项目分析豆瓣电影 Top250 公开榜单前 200 部影片，重点呈现评分分布、类型结构、国家/地区来源、年代分布和排名关系。下表为本次数据快照的核心结果。

项目	说明
电影数量	200 部
年份跨度	1936-2023
平均评分	9.01
中位评分	9.00
评分范围	8.5-9.7
累计评价人数	188,548,326
出现最多的类型	剧情
出现最多的国家/地区	美国
数量最多的年代	2000 年代

2. 主要发现

- Top200 电影评分集中在 8.8-9.3 区间，整体评分水平很高。
- 剧情片出现 150 次，是榜单中最突出的类型标签。
- 美国电影出现 110 次，在国家/地区来源中占比最高。
- 1990 年代、2000 年代和 2010 年代影片构成榜单主体，其中 2000 年代数量最多。
- 排名越靠前评分整体越高；评分与评价人数之间的线性相关性较弱。
- 机器学习扩展中，随机森林 的 5 折交叉验证 MAE 为 0.1459，优于平均分基线 0.2034。
- KMeans 分群形成华语剧情、欧美剧情、悬疑惊悚、动画奇幻等电影画像，可作为结果展示补充。

3. 类型与地区结构

类型分布显示，剧情片是 Top200 中最主要的标签，喜剧、爱情、冒险、奇幻和犯罪等类型也具有较高出现频次。国家/地区分布中，美国电影数量最多，日本、英国、中国香港、中国大陆和法国等也形成较明显的代表性。

类型	出现次数	国家/地区	出现次数
剧情	150 次	美国	110 次
喜剧	44 次	英国	28 次
爱情	43 次	日本	28 次
冒险	41 次	中国香港	24 次
奇幻	39 次	中国大陆	22 次
犯罪	36 次	法国	16 次
动画	34 次	韩国	11 次
惊悚	27 次	意大利	9 次

4. 机器学习探索

该扩展使用年份、距今年数、评价人数对数、类型标签数、国家/地区数，以及热门类型和国家/地区的多热编码，进行评分预测和电影画像分群。由于样本量只有 200 条且评分范围较窄，模型定位为探索性分析，不作为真实评分预测服务。

模型	MAE	RMSE	R²
平均分基线	0.2034	0.2426	-0.0088
岭回归	0.1700	0.2172	0.1814
随机森林	0.1459	0.1837	0.4171

特征重要性显示，评价人数（对数）、上映年份、距今年数和类型标签数对模型误差影响最大，说明榜单内评分差异与热度、年代及类型结构存在一定关系。

分群画像	数量	平均评分	代表影片
华语剧情高口碑片	26	8.946	霸王别姬、背靠背，脸对脸、活着、鬼子来了
欧美剧情经典片	98	9.074	肖申克的救赎、泰坦尼克号、阿甘正传、美丽人生
悬疑惊悚与犯罪片	31	8.910	控方证人、盗梦空间、无间道、蝙蝠侠：黑暗骑士
动画奇幻与冒险片	45	8.978	千与千寻、星际穿越、大闹天宫、疯狂动物城

5. 可视化结果




图 1 Top200 电影评分分布




图 2 热门电影类型出现次数




图 3 主要制片国家/地区出现次数




图 4 不同年代电影数量




图 5 排名与评分关系




图 6 机器学习评分预测 MAE 对比




图 7 随机森林置换特征重要性




图 8 电影画像分群二维投影

6. 项目输出

项目	说明
清洗数据	data/processed/movies_clean.csv
类型展开表	data/processed/movies_by_genre.csv
国家/地区展开表	data/processed/movies_by_country.csv
统计摘要	data/processed/analysis_summary.json
机器学习摘要	data/processed/ml_summary.json
电影分群结果	data/processed/movie_ml_clusters.csv
分析图表	output/figures/*.png
展示报告	GitHub 展示版 DOCX/PDF

7. 可复现操作

项目	说明
安装依赖	<code>python -m venv .venv; .venv\Scripts\python.exe -m pip install -r requirements.txt</code>
离线复现	<code>python run_pipeline.py --skip-fetch --student-name ... --student-id ... --class-name ...</code>
重新采集	<code>python run_pipeline.py --fetch --student-name ... --student-id ... --class-name ...</code>
运行 ML 扩展	<code>python scripts/run_ml_extension.py</code>
重建展示报告	<code>python scripts/build_github_showcase_report.py</code>
运行测试	<code>python -m pytest -q</code>

8. 项目实施说明

项目	说明
采集层	分页访问公开榜单页面，解析排名、片名、年份、国家/地区、类型、评分和评价人数。
清洗层	统一字段类型，处理多值字段，移除重复项，并输出一电影一行的主表。
分析层	生成评分、类型、国家/地区、年代和相关关系统计。
建模层	执行评分预测交叉验证、随机森林特征重要性分析和 KMeans 电影分群。
输出层	保存 CSV/JSON、PNG 图表、Word 报告和 PDF 报告。

9. 局限性

- 榜单数据代表公开页面的一次快照，不能直接外推到全部电影市场。
- 类型与国家/地区为多值字段，当前按出现次数统计。
- 机器学习扩展使用小样本高分榜单数据，适合展示建模流程与特征解释，不适合作为真实评分预测系统。
- 后续可加入交互式看板、自动化 CI 和更丰富的文本分析。