

豆瓣电影 Top200 数据分析项目

Python 数据采集、清洗、可视化与自动化报告生成

项目	说明
项目类型	端到端数据分析管道 / 课程项目展示版
数据对象	豆瓣电影 Top250 公开榜单前 200 部影片
核心技术	requests, BeautifulSoup4, pandas, scipy, matplotlib, python-docx, pytest
展示版本	去除个人身份信息，仅保留项目过程、结果和工程化说明

1. 项目亮点

- 端到端实现公开榜单采集、HTML 解析、字段清洗、统计分析、可视化和报告生成。
- 支持离线复现：基于已保存 CSV 可重建清洗数据、图表和报告。
- 对记录数、排名唯一性、关键字段缺失和重复项进行质量核验。
- 输出课程提交版与 GitHub 展示版两套报告，兼顾作业提交和项目展示。
- 使用 pytest 覆盖页面解析、数据清洗、拆分和统计摘要等核心逻辑。

2. 数据管道设计

项目	说明
采集层	分页访问公开榜单页面，解析排名、片名、年份、国家/地区、类型、评分和评价人数。
清洗层	统一字段类型，处理多值字段，移除重复项，并输出一电影一行的主表。
分析层	生成评分、类型、国家/地区、年代和相关关系统计。
输出层	保存 CSV/JSON、PNG 图表、Word 报告和 PDF 报告。

3. 关键结果

项目	说明
电影数量	200 部
年份跨度	1936-2023
平均评分	9.01
评分范围	8.5-9.7
累计评价人数	188,548,326
数量最多的年代	2000 年代

4. 类别与地区观察

类型分布显示，剧情片是 Top200 中最主要的标签，喜剧、爱情、冒险、奇幻和犯罪等类型也具有较高出现频次。国家/地区分布中，美国电影数量最多，日本、英国、中国香港、中国大陆和法国等也形成较明显的代表性。

类型	出现次数	国家/地区	出现次数
剧情	150 次	美国	110 次
喜剧	44 次	英国	28 次
爱情	43 次	日本	28 次
冒险	41 次	中国香港	24 次
奇幻	39 次	中国大陆	22 次
犯罪	36 次	法国	16 次
动画	34 次	韩国	11 次
惊悚	27 次	意大利	9 次

5. 可视化结果




图 1 Top200 电影评分分布




图 2 热门电影类型出现次数




图 3 主要制片国家/地区出现次数




图 4 不同年代电影数量




图 5 排名与评分关系

6. 工程化与复现

项目	说明
复现入口	run_pipeline.py --skip-fetch 可基于本地原始 CSV 重建结果。
展示报告	scripts/build_github_showcase_report.py 可单独重建本展示版 Word。
测试方式	python -m pytest -q
文档补充	README.md、docs/project_overview.md、docs/data_dictionary.md

7. 局限性与后续方向

- 榜单数据代表公开页面的一次快照，不能直接外推到全部电影市场。
- 类型与国家/地区为多值字段，当前按出现次数统计。
- 后续可加入交互式看板、自动化 CI、配置化运行和更丰富的文本分析。